

Introduction à Python et au Machine Learning

Cours 3 - Introduction au machine learning - algorithme des k plus proches voisins

Olivier Goudet

LERIA, Université d'Angers

11 février 2025



Section 1

Introduction


Qu'est-ce que le *machine learning* ?

- Tout d'abord, *machine learning* correspond en français aux termes *apprentissage automatique* ou *apprentissage statistique*.
- Le *machine learning* est un champ d'étude de l'intelligence artificielle qui se fonde sur des approches mathématiques et statistiques pour donner aux ordinateurs la capacité "d'apprendre" à partir de données.


Exemples de cas d'utilisation du Machine Learning

- Détection de fraudes.
- Systèmes de recommandation.
- Ajout en temps réel de publicités ciblées.
- Analyse de texte.
- Fouille de données.
- Prédiction de pannes.
- Modèles d'estimation de prix en finance.
- Filtres de spams.
- IA d'un jeu (échecs, go, bridge, Starcraft).

Machine Learning Process



3 principales problématiques en Machine Learning




1) Apprentissage supervisé

- **Données d'apprentissage** : exemples étiquetés (supervisé)
 N couples (entrée, étiquette): $(\mathbf{x}^1, y^1), \dots, (\mathbf{x}^N, y^N)$
- Chaque entrée $\mathbf{x}^i$ peut être décrite par un ensemble de d caractéristiques x_j^i (ou variables) avec des entrées réelles ou binaires $(x_1^i, x_2^i, \dots, x_d^i)$.
- **But** : Découvrir la relation entre $\mathbf{x}$ et y
 - Pour comprendre un phénomène.
 - Pour construire un modèle prédictif : prédire un label y_{pred} pour une nouvelle entrée $\mathbf{x}$ quand le "vrai" label y associé à $\mathbf{x}$ est inconnu.
- **Applications principales** :
 - Classification: y prend des valeurs discrètes (classes $0, 1, \dots, c$).
 - Régression: y prend des valeurs réelles (dans $\mathbb{R}$ généralement).

Exemple de problème de classification binaire

x




Does this molecule have good
photovoltaic properties ?

$y = 1$ (yes)
or
 $y = 0$ (no)

- **Encodage** : $x = (x_1, x_2, \dots, x_d) \in \mathbb{R}^d$ est un vecteur qui décrit les caractéristiques de la molécule, e.g. les types d'atomes, les distances inter-atomiques, etc...
- **Prédiction** : pour une nouvelle entrée x (nouvelle molécule), le y que l'on cherche à prédire est un label binaire indiquant si la molécule a de bonnes propriétés chimiques, oui (1) ou non (0).
- **Application concrète** : découverte de nouveaux matériaux pour créer des panneaux solaires.

Exemple de problème de classification multi-classe



Exemple de problème de classification multi-classe

- **En entrée** : image d'un chiffre en noir et blanc au format 8 pixels par 8 pixels.
- **Encodage** : chaque image peut être mise sous la forme d'un vecteur $\mathbf{x} = (x_1, x_2, \dots, x_{64}) \in [0, 1]^{64}$ où chaque $x_j \in [0, 1]$ correspond à l'intensité d'un des 64 pixels de l'image (e.g. 0: pixel noir, 1 : pixel blanc, 0.5 : pixel gris).
- **Prédiction** : pour une nouvelle entrée inconnue $\mathbf{x}$, le label y que l'on cherche à prédire est un chiffre entre 0 et 9 (10 classes).
- **Application concrète** : lecture automatique de chèques de banque.

Modèle d'apprentissage supervisé pour la classification

- **Vision informatique d'un modèle** : un modèle d'apprentissage supervisé pour la classification est un algorithme. En python, on écrirait une fonction

```
def f(x):  
    ....  
    return y_pred
```

→ par exemple f est l'algorithme des k plus proches voisins.

- **Vision mathématique d'un modèle** : un modèle d'apprentissage supervisé pour la classification est une fonction $f : \mathbb{R}^d \rightarrow \{0, \dots, c\}$.


→ par exemple f est un modèle de régression logistique, donné par $f(x) = \sigma(w_0 + w_1 x)$.

- **Vision probabiliste et statistique** : à partir de nouvelles entrées inconnues mises sous la forme de vecteurs $\mathbf{x}$, en général, on cherche le modèle f qui donne en moyenne des prédictions $y_{pred} = f(\mathbf{x})$, les plus proches possible des vrais y .

2) Apprentissage non supervisé

- **Données d'apprentissage** : exemples sans étiquettes
 N exemples $\mathbf{x}^1, \dots, \mathbf{x}^N$
- **But**: Découvrir des similarités dans les données et/ou construire un modèle génératif des données.
 - Meilleure compréhension des données
- **Applications** :
 - Clustering
 - Réduction de dimension : PCA, autoencoder
 - Modèles génératifs : e.g. generative adversarial neural networks (GAN).

Regroupement de molécules (Clustering)



Apprentissage par renforcement

■ Données d'apprentissage $\{(s_t, a_t, s_{t+1}, r_t)\}$:


s_t : un état dans lequel se trouve l'agent à au temps t

a_t : une action choisie au temps t

s_{t+1} : l'état atteint au temps $t + 1$ après avoir réalisé l'action a_t dans l'état s_t .


r_{t+1} : une récompense obtenue au temps $t + 1$ après avoir réalisé l'action a_t dans l'état s_t .

■ Objectif: Apprendre une stratégie qui maximise les récompenses obtenues sur un grand nombre de pas de temps.




Application de l'apprentissage par renforcement dans des jeux

- AlphaZero de Google DeepMind: achieved superhuman performance in chess [Silver et al. 2017, 2018]



AlphaZero

- AlphaZero: un algorithme de type *Monte Carlo Tree Search* (MCTS), guidé par un réseau de neurones profond (*deep learning*).
- Amélioration du réseau de neurones utilisé dans cet algorithme dans [Goudet et al. 2025] (à paraître).



IA de Google DeepMind pour le jeu de stratégie *Starcraft*

- AlphaStar : application de l'apprentissage par renforcement pour le jeu *Starcraft*.

Lien vers une démo :

<https://www.youtube.com/watch?v=VsJpWZj9jl0>



Au programme

Dans cette UE, on va parler d'apprentissage supervisé pour la classification binaire avec une présentation des algorithmes suivants :

- Algorithme des k plus proches voisins.
- Algorithme de régression logistique.
- Introduction aux réseaux de neurones pour la classification.

Section 2

Algorithme des k plus proches voisins

Algorithme des k plus proches voisins

- **Intuition** : pour estimer la sortie associée à une nouvelle entrée $\mathbf{x}$, on prend en compte (de façon identique) les labels (ou étiquettes) des k échantillons d'apprentissage dont l'entrée est la plus proche de la nouvelle entrée $\mathbf{x}$, selon une distance à définir.

Algorithme des k plus proches voisins

- Ensemble d'apprentissage $\{(\mathbf{x}^1, y^1), \dots, (\mathbf{x}^N, y^N)\}$ avec $\mathbf{x}^i$ dans $\mathbb{R}^d$ et y^i égal à 0 ou 1.
- Pour le calcul des plus proches voisins on a besoin d'une distance.
- On peut considérer différents types de distance, mais ici on va considérer la distance euclidienne :


$$d(\mathbf{x}, \mathbf{x}^i) = \|\mathbf{x} - \mathbf{x}^i\| = \sqrt{\sum_{j=1}^d (x_j - x_j^i)^2}$$

Prédictions



- Dans le cas d'une classification binaire (deux classes 0 ou 1), pour une nouvelle entrée $\mathbf{x}$, on calcule : $\text{vote}(\mathbf{x}) = \frac{1}{k} \sum_{i \in k \text{ plus proches voisins}(\mathbf{x})} y^i$.
- Si $\text{vote}(\mathbf{x}) > 0.5$ alors $y_{\text{pred}} = f(\mathbf{x}) = 1$. Si $\text{vote}(\mathbf{x}) < 0.5$ alors $y_{\text{pred}} = f(\mathbf{x}) = 0$. Si $\text{vote}(\mathbf{x}) = 0.5$ alors $y_{\text{pred}} = f(\mathbf{x})$ n'est pas précisée.
- Pour éviter le cas $\text{vote}(\mathbf{x}) = 0.5$ on peut choisir k impair.
- $\text{vote}(\mathbf{x}) \in [0, 1]$ donne une mesure de la confiance dans la décision.

Influence du paramètre k



- Le choix de k affecte la détermination de la classe pour un nouveau point.
- k est un hyperparamètre de la méthode des k plus proches voisins.



Frontière de décision - influence du paramètre k

k=1**k=5**

Frontière de décision - influence du paramètre k

k=10**k=50**

Intuitions : sous-apprentissage et sur-apprentissage

- Si k trop petit, f trop "compliqué" : sur-apprentissage (*overfitting*).
- Si k trop grand, f trop "simple" : sous-apprentissage (*underfitting*).
- Compromis frontière de décision simple/complicée.

Avantages de l'algorithme des k plus proches voisins

- Très simple
- Peut facilement s'étendre pour la classification à plus que deux classes.
- Pas de phase d'apprentissage à proprement parler.
- Il est facile d'ajouter plus de données pour la prédiction.
- Il y a très peu de d'hyperparamètres à spécifier : seulement le paramètre k et la métrique de distance utilisée.

Désavantages de l'algorithme des k plus proches voisins

- Le coût en mémoire peut être important, car il faut stocker l'ensemble des données d'apprentissage. Ne marche pas bien dans un contexte *big data*.
- Coût important de la prédiction car il faut a priori calculer les distances avec tous les points pour trouver les plus proches.
- Pas très bon en très haute dimension (quand la taille du vecteur d'entrée est très grande).